

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

PARTE I – IDENTIFICAÇÃO

Tipo do Relatório:	() Parcial (X) Final
Programa:	() PIBITI/CNPq () PIBITI/UFPI (X) ITV/UFPI
Título do Plano de Trabalho:	Aplicativo móvel para detecção e classificação de Úlceras do Pé Diabético
Nome do Orientador(a):	Rodrigo de Melo Sousa Veras
Nome do Orientando(a):	Edson Da Silva Lima Junior

PARTE II – RELATO TÉCNICO-CIENTÍFICO

1. Introdução

Segundo o IDF Diabetes Atlas, publicação periódica da International Diabetes Federation (IDF), organização global que reúne mais de 240 associações de diabetes em mais de 160 países (International Diabetes Federation, 2021), em 2021 havia aproximadamente 536,6 milhões de pessoas com diabetes no mundo (10,5% da população mundial adulta de 20-79 anos) as projeções indicam que em 2045 esse número poderá alcançar 783,2 milhões (12,2% da população adulta), na análise apresentada o custo global com saúde relacionado a Diabetes foi estimado em 966 bilhões de dólares em 2021, a região SACA (América do Sul e Central) foi responsável por aproximadamente 6,8% do total global estimado, ou seja, 65,3 bilhões de dólares.

A úlcera do pé diabético (DFU), uma das complicações mais graves da diabetes, corresponde a lesões abertas que acometem a pele e os tecidos subjacentes dos pés, frequentemente precedidas por trauma ou inflamação de baixo grau. Além de comprometer a função física e a qualidade de vida, as DFUs estão diretamente associadas a um risco elevado de desfechos graves. De acordo com Armstrong et al. (2023), estima-se que aproximadamente 18,6 milhões de pessoas em todo o mundo desenvolvam úlceras nos pés anualmente. Essas lesões precedem cerca de 80% das amputações de membros inferiores em indivíduos com diabetes e aumentam significativamente o risco de morte. A taxa de mortalidade em 5 anos para pessoas com DFU é de aproximadamente 30%, podendo ultrapassar 70% naqueles que sofrem uma amputação maior. Outro aspecto crítico é a alta taxa de recorrência: 42% em 1 ano e 65% em 5 anos, o que reforça a natureza crônica e persistente do problema.

Diante desse cenário alarmante, a identificação precoce das lesões é fundamental tanto para favorecer o processo de cicatrização quanto para prevenir complicações graves, como hospitalizações e amputações. A inteligência artificial (IA), especialmente por meio de modelos de *machine learning*, tem avançado rapidamente na medicina, permitindo que algoritmos aprendam a partir de grandes volumes de dados, identifiquem padrões complexos e até mesmo analisem imagens médicas com alta precisão. Essas ferramentas já vêm sendo aplicadas em diferentes áreas do cuidado em saúde, desde a previsão de eventos críticos, como episódios de hipoglicemia, até o apoio no manejo de complicações crônicas do diabetes. Nesse contexto, a aplicação de modelos de *machine learning* surge como uma solução promissora, com potencial para apoiar as equipes multidisciplinares já sobrecarregadas, auxiliando na previsão da evolução das DFUs e na tomada de decisão clínica sobre possíveis complicações. O uso da IA pode, assim, otimizar o tempo de profissionais e pacientes, além de contribuir para a redução dos custos de tratamento associados à gestão das DFUs (WEATHERALL et al., 2023).

Conforme destaca Ellahham (2020), a inteligência artificial tem se mostrado fundamental no desenvolvimento de modelos preditivos capazes de estimar o risco de diabetes e suas complicações, permitindo um cuidado mais personalizado. Além disso, a IA amplia a autonomia dos pacientes no gerenciamento de sua própria saúde e possibilita aos médicos oferecer intervenções mais oportunas por meio de plataformas tecnológicas, reduzindo custos e tempo de acompanhamento, inclusive com a coleta remota de dados.

Estudos que utilizam imagens de pés diabéticos e ferramentas de inteligência artificial, como algoritmos tradicionais de aprendizado de máquina e Redes Neurais Convolucionais (CNNs), têm sido amplamente desenvolvidos. A avaliação de úlceras do pé diabético (DFUs) com métodos computadorizados é essencial para apoiar os sistemas de saúde globais, uma vez que contribui para a melhoria dos procedimentos de triagem e monitoramento, além de reduzir o tempo de hospitalização para pacientes e profissionais da saúde. Esses experimentos buscam aprimorar o reconhecimento, a detecção e a

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

segmentação das características visuais das úlceras, logo, o uso de aprendizado de máquina na identificação de condições críticas como isquemia e infecção em DFUs oferece um caminho promissor para o diagnóstico remoto e eficiente dessas complicações (Goyal et al., 2018).

O uso de smartphones no contexto do monitoramento do pé diabético também avançou como uma alternativa prática e acessível, como evidenciado por Cassidy et al. (2023). Os autores destacam o crescimento expressivo de aplicativos de saúde e seu papel no automonitoramento, reforçando a viabilidade dessa tecnologia em larga escala. No estudo, foram utilizados smartphones de baixo custo, com diferentes qualidades fotográficas, para avaliar a robustez do algoritmo de IA em cenários reais, demonstrando que a solução não depende de hardware sofisticado. Além disso, o sistema apresentou um tempo médio de resposta de apenas 5,866 segundos por caso, indicando praticidade e eficiência para uso clínico e domiciliar. Outro ponto relevante é o potencial para rastreamento remoto e automonitoramento, permitindo que pacientes, cuidadores ou familiares capturem imagens das lesões em casa, reduzindo a necessidade de visitas hospitalares e proporcionando maior tranquilidade. Essas evidências reforçam que soluções baseadas em smartphones estão alinhadas às tendências atuais de saúde digital e podem contribuir significativamente para a prevenção e o acompanhamento das DFUs.

Diante desse cenário, o presente projeto tem como objetivo principal o desenvolvimento de uma solução tecnológica integrada para auxiliar profissionais da saúde no manejo de úlceras do pé diabético (DFUs). A proposta contempla a criação de um aplicativo móvel com ferramentas de inteligência artificial (IA) para detecção e classificação de lesões. Essa abordagem busca otimizar o processo diagnóstico, tornando-o mais ágil e preciso, o que é fundamental para um tratamento mais seguro e para a prevenção da progressão das lesões.

A escolha de uma plataforma móvel visa ampliar o alcance e a acessibilidade da solução, permitindo que as funcionalidades sejam executadas em smartphones. Isso possibilita tanto o monitoramento clínico por profissionais quanto o automonitoramento remoto pelos próprios pacientes ou seus cuidadores. Desse modo, o projeto busca contribuir para a melhoria da qualidade do cuidado, otimizar o tempo de profissionais e pacientes e apoiar a redução dos custos associados ao tratamento e acompanhamento das DFUs.

2. Revisão de Literatura

Ao longo dos anos, diversos autores têm dedicado seus estudos ao desenvolvimento de soluções baseadas em aprendizado de máquina para o reconhecimento e classificação de lesões do pé diabético (DFUs). Esta seção apresenta e discute trabalhos que contribuem significativamente para essa área da ciência, demonstrando o progresso e os desafios do campo.

O estudo de Harahap et al. (2022) teve como objetivo analisar a acurácia de modelos de Redes Neurais Convolucionais (CNNs) na classificação de úlceras diabéticas utilizando a abordagem de *transfer learning*. O trabalho avaliou arquiteturas pré-treinadas como VGG19, MobileNetV2 e ResNet (ResNet50V2, ResNet101V2, ResNet152V2). Os resultados indicaram que o modelo ResNet152V2 obteve a melhor acurácia, com 99,3%, demonstrando ser altamente eficaz para a classificação de úlceras em pacientes com diabetes.

Outro trabalho relevante, de Goyal et al. (2018), propôs o uso de CNNs para a classificação de DFU, introduzindo a arquitetura DFU-net. O modelo foi projetado para extrair características que diferenciam a pele saudável da pele com úlcera. A pesquisa, que comparou a DFU-net com outros classificadores de *machine learning* e *deep learning*, como GoogLeNet e AlexNet, alcançou uma pontuação AUC de 0,961, superando os demais e sugerindo um potencial para um "paradigma de mudança no cuidado do pé diabético".

Em uma revisão abrangente sobre deep learning para úlceras do pé diabético, Zhang et al. (2022) examinaram diversas metodologias para classificação, detecção de objetos e segmentação semântica. O estudo concluiu que as tarefas de classificação são predominantemente baseadas em CNNs, destacando o desempenho superior de modelos com camadas convolucionais paralelas, como o GoogLeNet, e modelos de conjunto (ensemble). Para a detecção de objetos, o artigo mencionou arquiteturas como Faster R-CNN, YOLO v3, YOLO v5 e EfficientDet. Já para a segmentação, o modelo U-Net foi apontado como o de melhor desempenho, com 94,96% de acurácia.

Complementando essa visão, Goyal et al. (2020) investigaram a discriminação de isquemia e infecção em úlceras do pé diabético, introduzindo um novo conjunto de dados com rótulos de isquemia e infecção, o que foi o primeiro estudo desse tipo para pesquisa. Eles propuseram um modelo de Ensemble CNN que superou algoritmos tradicionais, alcançando 90% de acurácia na classificação de isquemia e 73% na de infecção. O trabalho também ressaltou os desafios da classificação, como a dificuldade de reconhecer infecções a partir de imagens não padronizadas, sugerindo que a precisão poderia ser melhorada com a inclusão de dados de testes clínicos, como exames de sangue.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

Por fim, Cassidy et al. (2023) realizaram uma avaliação clínica de um sistema de inteligência artificial em um smartphone de baixo custo para a detecção de úlceras do pé diabético. O sistema demonstrou alta acurácia, com sensibilidade de 0,9157 e especificidade de 0,8857. Os autores destacaram que essa tecnologia é o primeiro passo crucial para a criação de um sistema totalmente automatizado de detecção e monitoramento de DFUs, com o potencial de reduzir as visitas hospitalares e melhorar os resultados de saúde.

3. Metodologia

Para o desenvolvimento do projeto seguimos a metodologia de desenvolvimento de software Waterfal, a escolha desse modelo se deu pela estabilidade e clareza do projeto com base nos requisitos, essa metodologia é linear e cada fase do desenvolvimento é concluída e então iniciada a próxima. O projeto seguiu as seguintes etapas, levantamento de análise de requisitos, projeto de arquitetura, implementação e testes iniciais, com modelo simples e etapas claramente definidas foi possível gerenciar o projeto com maior facilidade e produzir o mínimo produto viável (MVP) do projeto. O desenvolvimento focou em suprir requisitos pré-estabelecidos, os quais serão descritos no relatório.

3.1 Arquitetura do Projeto

A arquitetura do projeto DFU foi concebida para ser modular e escalável, utilizando uma abordagem de microsserviços para dividir as responsabilidades em componentes independentes. A solução é composta por três camadas principais: a aplicação móvel (Frontend), a API de backend e o microsserviço de Inteligência Artificial.

3.1.1 Frontend

O frontend é uma aplicação móvel híbrida, desenvolvida em React Native com Expo. Ele é a interface direta com o usuário, permitindo a interação de profissionais de saúde no acompanhamento e análise de úlceras. As principais funcionalidades são:

- **Navegação e Rotas:** Utiliza a biblioteca expo-router para gerenciar a navegação entre as diferentes telas da aplicação, como a tela de login, cadastro, a lista de pacientes e as telas de análise de imagens.
- **Autenticação:** O gerenciamento de usuários é realizado através da biblioteca firebase, que se integra diretamente com o Firebase Authentication para login e registro, garantindo a segurança dos dados de acesso.
- **Interação com o Backend:** A aplicação se comunica com o backend via requisições HTTP, enviando dados do usuário e imagens para processamento e recebendo as informações de análise e status.

3.1.2 Backend

O backend é uma API robusta construída em Node.js com o framework Express. Ele atua como o cérebro da aplicação, coordenando o fluxo de dados e a comunicação entre o frontend e o microsserviço de IA. Suas responsabilidades incluem:

- **Gerenciamento de Banco de Dados:** Utiliza o MongoDB, um banco de dados NoSQL, com o ODM (Object-Document Mapper) Mongoose para modelar e gerenciar a persistência dos dados de pacientes e as análises realizadas.
- **Autenticação de APIs:** As rotas são protegidas e autenticadas usando o Firebase Admin SDK, que valida os tokens de autenticação enviados pelo frontend, garantindo que apenas usuários autorizados possam acessar os recursos da API.
- **Processamento e Armazenamento de Imagens:** Recebe as imagens do frontend e as armazena no Firebase Storage, um serviço de armazenamento de objetos em nuvem, otimizado para arquivos de mídia.
- **Comunicação com o Microsserviço de IA:** Funciona como um orquestrador, enviando as imagens para o microsserviço de IA para processamento e aguardando o retorno dos resultados, que são então salvos no banco de dados e enviados de volta para o frontend.

3.1.3 Microsserviço de Inteligência Artificial

Este componente é uma API separada, escrita em Python utilizando o framework FastAPI, dedicada exclusivamente às operações de inteligência artificial. Isso garante que o processamento pesado de IA não sobrecarregue o backend principal. O microsserviço possui dois modelos de Machine Learning integrados:

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

- **Deteção de Úlceras:** Um modelo de visão computacional, baseado nos algoritmos, é responsável por analisar a imagem enviada e identificar a presença de úlceras, desenhando caixas delimitadoras (bounding boxes) ao redor das áreas detectadas.
- **Classificação de Úlceras:** Após a deteção, as áreas delimitadas são passadas para um segundo modelo, construído com TensorFlow/Keras, que classifica a úlcera de acordo com sua gravidade ou tipo, fornecendo uma análise detalhada.

3.2, Requisitos

A aplicação final foi desenvolvida com base em um conjunto de requisitos funcionais e não funcionais detalhadamente definidos para atender às necessidades dos usuários e aos padrões técnicos do projeto.

3.2.1 Requisitos Funcionais

Os requisitos funcionais especificam o que o sistema deve fazer para cumprir os objetivos do projeto. São eles:

1. A aplicação deve ser voltada para dispositivos móveis, com suporte para sistemas Android e iOS.
2. A aplicação deve permitir ao usuário tirar fotos das condições médicas.
3. O produto deve fornecer análise e feedback imediatos sobre as imagens capturadas, favorecendo o processo de deteção e classificação.
4. O aplicativo deve permitir o diagnóstico de imagens por meio do pós-processamento delas, otimizando a utilização de recursos.
5. O aplicativo deve diagnosticar Úlceras do Pé Diabético, pois permite a realização do tratamento.
6. O produto deve rastrear a progressão da condição de um paciente ao longo do tempo, permitindo que os profissionais de saúde ajustem os planos de tratamento conforme necessário.
7. A aplicação deve permitir que os médicos acessem e gerenciem facilmente sua lista de pacientes, o que agiliza o processo de atendimento.
8. O aplicativo deve manter registro dos exames realizados em um paciente para favorecer a tomada de decisões.
9. O produto deve ter um local para o médico deixar seu parecer técnico, aumentando a confiabilidade do sistema.
10. O aplicativo deve ter um espaço para comentários/notas do médico sobre o diagnóstico, oferecendo um espaço dedicado para profissionais de saúde anotarem e discutirem achados de diagnósticos específicos.
11. Deve haver uma galeria de imagens do paciente, organizando todas as imagens capturadas por paciente, facilitando o acesso aos dados históricos para comparação e análise.
12. O médico deve ter acesso ao histórico médico do paciente.

3.2.2 Requisitos Não Funcionais

Os requisitos não funcionais definem as qualidades e restrições do sistema, como desempenho, segurança e usabilidade. São eles:

1. A deteção síncrona deve ser realizada em até 2 segundos.
2. Os resultados do diagnóstico devem ser retornados ao usuário em até 30 segundos.
3. O sistema deve ser escalável para outros tipos de enfermidades diagnosticáveis por meio de imagem.
4. O relatório exportado deve ser em formato PDF.
5. A aplicação deve ter acesso ao recurso de câmera do dispositivo.
6. Somente usuários cadastrados podem utilizar as funcionalidades.
7. Os dados dos pacientes devem ser protegidos de acordo com a LGPD.

3.3 Escolha de ferramentas e tecnologias

A seleção das tecnologias foi uma decisão estratégica, visando atender aos requisitos do projeto e garantir uma arquitetura robusta, escalável e de fácil manutenção. As escolhas principais para cada componente são justificadas a seguir.

No frontend da aplicação a escolha do React Native foi motivada pela necessidade de desenvolver uma aplicação para dispositivos móveis que funcionasse em sistemas operacionais Android e iOS, conforme

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

os requisitos não funcionais. O uso do Expo simplifica o ambiente de desenvolvimento, a prototipagem e o processo de construção e distribuição da aplicação, acelerando o ciclo de desenvolvimento. A integração com o Firebase para autenticação de usuários é justificada pela robustez, segurança e facilidade de implementação que a plataforma oferece, garantindo um sistema de login e cadastro confiável.

O backend foi construído com Node.js e Express para aproveitar o modelo de E/S assíncrona e não bloqueante, ideal para uma API que gerencia requisições concorrentes de usuários, garantindo alto desempenho. Express, como um framework minimalista, permitiu a construção de uma API flexível e otimizada. O uso do MongoDB, um banco de dados NoSQL, é apropriado para a flexibilidade na modelagem dos dados de pacientes, que podem não ter uma estrutura fixa. O Mongoose, como ODM, facilita a interação com o banco de dados, simplificando a definição de esquemas e a manipulação dos dados. A escolha do Firebase Admin SDK complementa a autenticação do frontend, permitindo que o backend valide tokens de usuários de forma segura. O Firebase Storage foi selecionado como solução de armazenamento de imagens por ser um serviço em nuvem escalável e otimizado para arquivos de mídia, desacoplando o armazenamento do banco de dados principal e garantindo eficiência.

Python foi a escolha natural para o microserviço de IA devido ao seu vasto ecossistema de bibliotecas para aprendizado de máquina. O FastAPI foi selecionado pela sua alta performance e facilidade de criação de APIs, o que é crucial para garantir a rapidez no retorno dos resultados do diagnóstico, atendendo aos requisitos de tempo de resposta.

3.4 Dataset, Modelos de Inteligência Artificial, Métodos e Métricas de Avaliação

Esta subseção detalha o conjunto de dados utilizado, os modelos de IA implementados, os métodos de treinamento e as métricas de avaliação empregadas para garantir a precisão e a confiabilidade do sistema.

3.4.1 Dataset de Treinamento e Validação

Para o desenvolvimento deste trabalho, foi utilizado o mesmo conjunto de dados descrito por Santos et al. (2025), proveniente das edições de 2020 e 2021 do *Diabetic Foot Ulcer Challenge (DFUC)*. Esse dataset, que totaliza 8.242 imagens, foi coletado em hospitais de Lancashire, no Reino Unido, e anotado por especialistas clínicos. Ele contempla quatro classes de interesse: ausência de lesão, presença de infecção, presença de isquemia e ocorrência simultânea de infecção e isquemia.

No caso específico dos modelos de detecção, foi empregado o DFUC 2020, caracterizado por imagens do pé inteiro acompanhadas de arquivos CSV com as coordenadas das caixas delimitadoras (*bounding boxes*) das úlceras. Já para os modelos de classificação, utilizou-se o DFUC 2021, no qual as imagens estão centradas nas regiões ulceradas e categorizadas diretamente nas quatro classes mencionadas.

3.4.2 Modelos de IA e Métodos de Processamento

Conforme mencionado anteriormente, o objetivo do sistema é integrar um aplicativo móvel a ferramentas de inteligência artificial capazes de detectar e classificar úlceras do pé diabético. Para isso, foram treinados modelos distintos para cada tarefa.

Na etapa de detecção, foram exploradas as arquiteturas YOLOv5 e YOLOv8, reconhecidas pela eficiência e velocidade em aplicações de detecção em tempo real. Esses modelos receberam como entrada o DFUC 2020, no qual cada imagem contém o pé completo e não apenas a lesão isolada. As caixas delimitadoras das úlceras foram obtidas a partir dos arquivos CSV fornecidos junto ao dataset. O objetivo foi treinar os modelos para, ao receber uma nova imagem, localizar automaticamente as úlceras por meio das *bounding boxes*, recortando as subimagens que seriam posteriormente analisadas pelos classificadores. O treinamento dos modelos de detecção foi realizado ao longo de 50 épocas, adotando uma divisão estratificada de 80% para treino, 10% para validação e 10% para teste, assegurando representatividade equilibrada nas três etapas.

Na fase de classificação, foi conduzida uma análise comparativa envolvendo diferentes arquiteturas de redes neurais convolucionais pré-treinadas e ajustadas por *transfer learning*, incluindo DenseNet121, EfficientNetB3, InceptionV3, ResNet50, Xception, DenseNet201, VGG19, ResNet50V2, ResNet101V2, ResNet152V2, InceptionResNetV2 e MobileNetV2. Além disso, foi implementada a DFUNetv5, arquitetura originalmente proposta por Goyal et al. (2018), reconhecida por seu bom desempenho na classificação de úlceras.

Nessas o conjunto de imagens foi o do dataset supracitado com 8242 itens, imagens focadas apenas na úlcera. O treinamento seguiu o paradigma de aprendizado por transferência, no qual a base de cada rede foi inicializada com pesos pré-treinados no ImageNet, e a camada de saída original foi substituída por uma nova cabeça de classificação composta por:

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

- uma camada GlobalAveragePooling2D, que reduz a dimensionalidade dos mapas de características;
- uma camada Dense com 512 neurônios e ativação *ReLU*, responsável por extrair representações de alto nível;
- uma camada Dropout (taxa 0,4), para mitigar *overfitting*;
- uma segunda camada Dense com 256 neurônios e ativação *ReLU*, seguida de outra camada Dropout (taxa 0,4), adicionando regularização extra;
- uma camada final Dense, com número de neurônios equivalente às quatro classes, utilizando ativação *softmax* para fornecer a probabilidade de cada categoria.

O treinamento ocorreu ao longo de 12 épocas, aplicando-se pesos de classe para compensar o desbalanceamento entre as categorias e dar maior relevância às classes minoritárias, os dados de classificação foram consolidados em um único conjunto e divididos de forma estratificada em 80% para treino, 10% para validação e 10% para teste. Esse procedimento assegurou que cada classe estivesse proporcionalmente representada em todas as fases, reduzindo viés e proporcionando uma avaliação mais robusta e justa do desempenho dos modelos.

3.4.3 Métricas de Avaliação

Aqui serão escritas todas as regras para as classificações e detecções, como são tipos diferentes de treinamentos e objetivos, parte das métricas para avaliação também foram diferentes, buscando encontrar as que melhor representassem a efetividade para cada tipo de modelo.

3.4.3.1 Métricas para Modelos de Classificação

A avaliação dos modelos foi realizada levando em conta as seguintes métricas a partir de 4 valores principais, Verdadeiros Positivos (VP), Verdadeiros Negativos(VN), Falsos Negativos (FN) e Falsos Positivos(FP).

Acurácia: É a proporção de previsões corretas feitas pelo modelo em relação ao total de previsões.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

Precisão: Mede a proporção de previsões positivas corretas entre todas as previsões positivas realizadas pelo modelo.

$$Precisão = \frac{VP}{VP + FP}$$

Recall: Indica a capacidade do modelo de identificar corretamente todas as instâncias positivas em um conjunto de dados.

$$Recall = \frac{VP}{VP + FN}$$

F1-score: Combina a precisão e o recall em uma única medida, sendo uma média harmônica que indica o equilíbrio entre as duas métricas.

$$F1 = 2 \times \frac{P \times R}{P + R}$$

Coeficiente Kappa (κ): Avalia a concordância entre as classificações do modelo e as classificações reais, ajustando para a concordância que ocorreria por acaso.

$$Kappa = \frac{Po - Pe}{1 - Pe}$$

- Po é a proporção de concordância observada.
- Pe é a proporção de concordância esperada ao acaso.

3.4.3.2 Métricas para Modelos de Detecção

A avaliação do desempenho do modelo de detecção de objetos (YOLOv8) foi realizada no conjunto de teste, utilizando métricas específicas que garantem a precisão das previsões de caixas delimitadoras e classificações.

- mAP@0.5 (Mean Average Precision): Esta métrica avalia a precisão média do modelo para uma IoU (Intersection over Union) de 0.5. Essencialmente, mede a proporção de detecções corretas com uma sobreposição de 50% ou mais com a caixa delimitadora real. É uma das métricas mais importantes e frequentemente utilizada para avaliar a performance de modelos de detecção de objetos.
- mAP@0.5:0.95 (Mean Average Precision): Esta é uma métrica mais rigorosa, calculando a média das precisões médias em vários limiares de IoU, variando de 0.5 a 0.95, com incrementos de 0.05. Ela oferece uma visão mais abrangente e completa da precisão do modelo em diferentes níveis de sobreposição.
- Precisão : Mede a proporção de detecções de úlceras que foram realmente corretas, ou seja, de todas as caixas delimitadoras previstas pelo modelo, qual porcentagem delas corresponde a uma úlcera real.
- Recall: Avalia a capacidade do modelo de encontrar todas as úlceras presentes nas imagens. Ela mede a proporção de úlceras reais que foram detectadas com sucesso pelo modelo.
- F1-Score: Esta métrica é uma média harmônica entre a precisão e a revocação. Ela é útil para encontrar um equilíbrio entre as duas métricas e fornece uma única medida de desempenho, sendo particularmente relevante em cenários onde tanto a identificação correta quanto a totalidade das detecções são importantes.

4. Resultados e discussão

Nesta seção serão apresentados os resultados do MVP do produto apresentado no projeto, isso será feito através da apresentação do fluxo de telas dentro da aplicação bem como a explicação de cada fase, posteriormente uma avaliação dos resultados dos modelos de detecção e classificação a partir das métricas supracitadas.

4.1 Minimum Viable Product (MVP)

Nessa seção irei mostrar a iteração com a aplicação do ponto de vista do usuário, isso será feito por meio de capturas de tela realizadas por um dispositivo móvel rodando aplicação, seguiremos um fluxo lógico de iteração com intuito de apresentar as principais características do App e facilitar a visualização do comportamento do produto em cada fase.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

(Tela 1)

(Tela 2)

Telas responsáveis pelo cadastro do profissional da saúde e coleta inicial dos dados sensíveis e profissionais do profissional de saúde, todos esses dados ficam salvos como forma de autenticação.

(Tela 3)

(Tela 4)

(Tela 5)

As telas 3, 4 e 5 mostram tipos de cadastros diferenciados para cada tipo de profissional da saúde (o usuário escolhe qual se encaixa no registro), para médicos adicionamos o campo CRM, registro que médicos devem ter para atuar legalmente no Brasil e que os identifica, para enfermeiros o campo COREN, registro

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

ligado a enfermagem e equivalente ao CRM para médicos, ambos emitidos pelos seus respectivos conselhos regionais, e na classe outros (como estagiários ou assistentes de saúde) esse tipo de dado não é coletado.

Edson Limci Med

CPF
12345678953

E-mail
medicoUm@email.com

Senha

Tipo de profissional
Médico

CRM
123456789

Telefone
86123456789

Cadastrar

Já tenho conta

(Tela 6)

A tela 6 mostra um exemplo de cadastro completo, em que todos os dados estão preenchidos corretamente.

Meus Pacientes

Buscar por nome ou CPF...

Pacientes 0

Nenhum paciente encontrado
Comece cadastrando seu primeiro paciente

Cadastrar Primeiro Paciente

Início Cadastrar

(Tela 7)

Novo Paciente
Preencha os dados do paciente

Dados Pessoais

Nome Completo *
Digite o nome completo

CPF *
000.000.000-00

Data de Nascimento *
dd/mm/aaaa

Gênero *
Selecione o gênero

Informações de Contato

Telefone *
(00) 00000-0000

Início Cadastrar

(Tela 8)

Informações de Contato

Telefone *
(00) 00000-0000

E-mail
exemplo@email.com

Endereço
Rua, número, bairro, cidade

Informações Adicionais

Plano de Saúde
Nome do plano de saúde

Cadastrar Paciente

Início Cadastrar

(Tela 9)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

Tela 7 mostra a tela inicial do aplicativo, ou seja ao passar da tela de login e/ou cadastro, como acabamos de criar esse usuário ainda não possui pacientes vinculados a ele, a tela 8 e 9 mostram a base de cadastro para um paciente, a partir disso ele poderá registrar novos pacientes.

(Tela 10)

(Tela 11)

(Tela 12)

Tela 10 e 11 mostram um cadastro completo de um paciente. Tela 12 mostra aviso de sucesso de cadastro de um paciente.

(Tela 12)

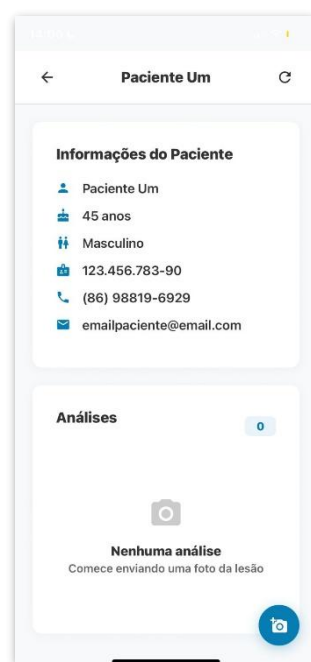
(Tela 13)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

Tela 12 e 13 mostram que a aplicação (MVP) consegue lidar com inconsistências de cadastro.



(Tela 14)



(Tela 15)


Tela 14 mostra a atualização dos pacientes ao adicionar um novo cadastro, é nessa tela que todos os pacientes de um determinado profissional ficam armazenados, a barra de pesquisa na parte superior da tela permite que o nome e o CPF sejam usados como objeto de pesquisa para encontrar pacientes, isso permite uma maior facilidade de gerenciamento para o profissional ao buscar com diversos pacientes. A tela 15 mostra a tela de um paciente recém-criado, em que nenhuma análise de DFU foi conduzida ainda, nessa tela temos de início na parte superior uma descrição com as informações básicas do paciente selecionado.




(Tela 16)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

Tela 16 mostra a etapa número 1 de uma nova análise de um paciente em que se escolhe a imagem.

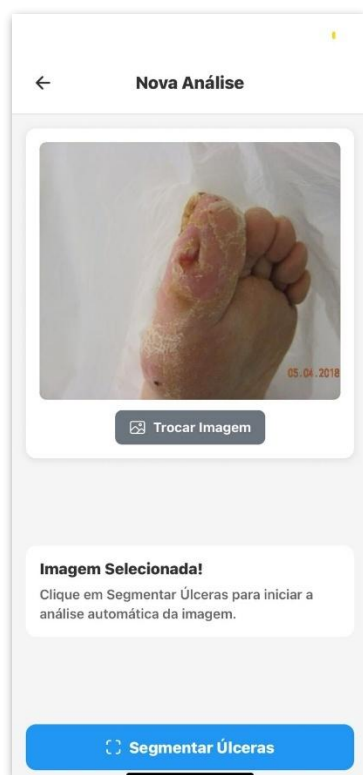


(Tela 17)



(Tela 18)

A tela 17 e a tela 18 mostra o fluxo escolhendo cada uma das opções da tela 16. (Imagens foram borradas artificialmente para serem colocadas no relatório)



(Tela 19)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

A tela 19 mostra a etapa pré-deteccção de determinada foto seleccionada ou tirada.



(Tela 20)

A tela 20 apresenta o resultado da segmentação automática utilizando um dos modelos treinados e colocados no servidor para lidar com as requisições relacionadas a inteligência artificial (Nesse caso o modelo de detecção utilizado foi o YoloV5), ao apertar em continuar se inicia a etapa de classificação.



(Tela 21)



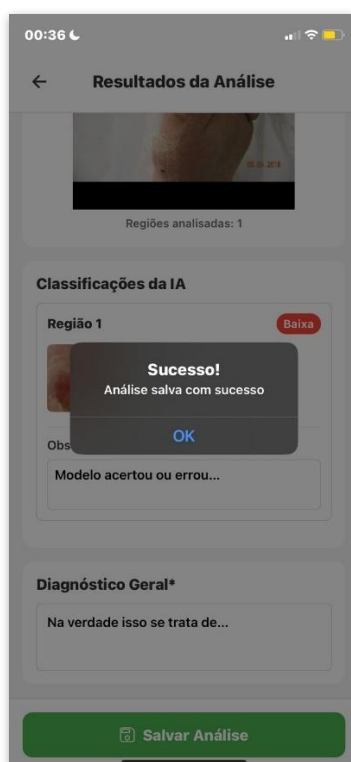
(Tela 22)



(Tela 23)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

A tela 21, 22 e 23 mostram as etapas agora após a detecção e a classificação, aqui implementei campos tanto para observações em relação a regiões específicas, visto que é comum que em condições como estas possa aparecer mais de uma úlcera e portanto mais de uma região detectada, quanto o diagnóstico geral do paciente, o a análise só pode ser salva após o profissional da saúde escrever o diagnóstico geral dentro da análise, nessa etapa os modelos de classificação podem retornar quatro tipos de classificação, pé sem infecção e sem isquemia, apenas com infecção, apenas com isquemia e com ambos, infecção e isquemia. A classificação é feita com base na probabilidade de cada classe definida pelo modelo, a que tiver maior probabilidade, segundo o modelo de IA, retorna ao frontend (interface com o usuário) como resposta da IA. (O modelo de classificação utilizado nas imagens foi apenas o de fallback, ou seja, apenas para evitar um travamento do sistema e permitir seguir o fluxo de maneira mais ágil nos testes.)



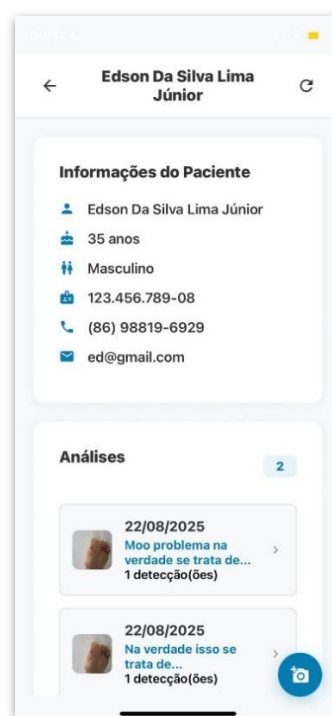
(Tela 24)

A tela 24 mostra a mensagem de sucesso após o salvamento bem sucedido de uma análise de determinado paciente, após isso na aba daquele paciente o médico poderá consultar todas as análises feitas.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI



(Tela 25)



(Tela 26)

Tela 25 e 26 mostram um outro paciente em outra conta, esse paciente tem duas análises que ficaram armazenadas no seu histórico e podem ser acessadas ao clicar no card do paciente. Todo esse acesso é feito de forma hierárquica, iterativa, e rápida dentro da aplicação.



(Tela 27)



(Tela 28)

A tela 27 e 28 são telas que mostram a tela após a seleção de uma das análises, aqui obtemos o resumo na parte superior, as regiões e observações de cada uma logo abaixo em seguida o diagnóstico geral e por fim algumas informações técnicas daquela análise específica.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

4.2 Resultados do Treinamento com Modelos de Classificação

Modelo	Acurácia	Precisão (Ponderada)	Revocação (Ponderada)	F1-Score (Ponderado)	Coefficiente Kappa
ResNet50	0.822463768115942	0.8280362517130004	0.822463768115942	0.8239823487939546	0.7103365556237774
ResNet50V2	0.8128019323671497	0.8165663307520142	0.8128019323671497	0.8135742915888327	0.6926974336380658
ResNet101V2	0.8019323671497585	0.8029137388376519	0.8019323671497585	0.8020933656421834	0.6774000427624546
DenseNet201	0.8007246376811594	0.801652527124409	0.8007246376811594	0.8010424652305068	0.672535869570428
ResNet152V2	0.7934782608695652	0.7940442000689302	0.7934782608695652	0.7932583137201719	0.6636752766125239
EfficientNetB3	0.785024154589372	0.7865720561468084	0.785024154589372	0.7842809014266414	0.6526780159493242
MobileNetV2	0.7814009661835749	0.7826805080365801	0.7814009661835749	0.7818110839371698	0.6403973509933776
Xception	0.7741545893719807	0.7780625222845342	0.7741545893719807	0.772871455662997	0.6316392998015883
DenseNet121	0.7463768115942029	0.7494271134210974	0.7463768115942029	0.7442376042855363	0.5875418080034158
InceptionV3	0.7379227053140096	0.7574865581468081	0.7379227053140096	0.7426141697608056	0.5845161290322581
VGG19	0.7318840579710145	0.7396768630616186	0.7318840579710145	0.7326799694681716	0.5713526169000159
Inception ResNet V2	0.7246376811594203	0.7446411050919612	0.7246376811594203	0.729769477325529	0.5644960367626026
DFUNet	0.7210144927536232	0.7485641804207914	0.7210144927536232	0.7175686453933079	0.5397365495401408

(Tabela de resultados de classificação)

A tabela acima conta com as métricas resultantes dos modelos classificatórios quando executados sobre o grupo de teste (Dados diferentes dos que foram utilizados para treino e validação). As métricas supracitadas foram coletadas de forma ponderada, ou seja, cada classe contribui para o cálculo de acordo com a sua proporção no conjunto de dados, evitando que o desempenho em classes pequenas distorça a avaliação geral. O ResNet50 se destacou com os melhores resultados em praticamente todas as métricas: maior Acurácia (0,8225), maior Precisão Ponderada (0,8280), maior Revocação Ponderada (0,8225), maior F1-Score Ponderado (0,8240) e maior Coeficiente Kappa (0,7103). Esses valores mostram que o modelo não apenas acerta mais, mas também mantém equilíbrio entre identificar corretamente os casos positivos (Revocação) e evitar falsos positivos (Precisão), além de apresentar excelente concordância com as classificações reais. As demais arquiteturas da família ResNet (ResNet50V2, ResNet101V2 e ResNet152V2) também exibiram métricas elevadas, com Acurácias acima de 0,79, Precisões e Revocações Ponderadas equilibradas e Coeficientes Kappa superiores a 0,66, confirmando a eficiência dessa arquitetura residual para o problema. O DenseNet201 apresentou desempenho muito próximo, destacando-se também como uma opção robusta.

Já os modelos EfficientNetB3, MobileNetV2 e Xception obtiveram resultados intermediários, com Acurácias entre 0,77 e 0,78, além de valores consistentes de Precisão e Revocação Ponderadas, mas ainda abaixo dos modelos líderes.

4.3 Resultado do Treinamento dos Modelos de Detecção

Modelo	Precisão	Revocação	mAP_50	mAP_50-95	F1-Score
YOLOv5	0.852	0.714	0.811	0.475	0.777
YOLOv8	0.832	0.708	0.796	0.471	0.765

(Tabela de resultados de detecção)

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

De acordo com a tabela de resultados dos modelos de detecção, os modelos YOLOv5 e YOLOv8 apresentaram resultados bastante semelhantes no conjunto de avaliação. Em termos de precisão, que indica a capacidade de evitar falsos positivos, o YOLOv5 obteve 0,852 contra 0,832 do YOLOv8. Já na revocação, que mede o quanto o modelo conseguiu identificar corretamente as úlceras presentes, os valores também foram próximos, 0,714 para o YOLOv5 e 0,708 para o YOLOv8. Na métrica mAP@50, que avalia a média de acertos considerando 50% de sobreposição entre a região prevista e a real, o YOLOv5 alcançou 0,811, enquanto o YOLOv8 obteve 0,796. Quando se considera a métrica mais rigorosa mAP@50-95, que leva em conta diferentes limiares de sobreposição, os valores foram 0,475 para o YOLOv5 e 0,471 para o YOLOv8. Por fim, no F1-Score, que representa o equilíbrio entre precisão e revocação, o YOLOv5 obteve 0,777 contra 0,765 do YOLOv8. De maneira geral, ambos os modelos apresentaram desempenho consistente e equilibrado em todas as métricas avaliadas, demonstrando capacidade satisfatória para a tarefa de detecção de úlceras do pé diabético.

5. Conclusão

O projeto obteve êxito ao entregar o MVP planejado no início, a aplicação se mostrou eficaz no processo de análise e armazenamento automático de dados dos profissionais de saúde e pacientes, e a na integração com modelos de IA atuando de forma remota ligados a aplicação, o projeto se consolida como um efeito da inovação na visão computacional aliada à saúde, com o fim de entregar uma ferramenta que ajude diretamente médicos, enfermeiros ou relacionados. Contudo, o mínimo produto viável não é o fim, são necessários testes práticos dentro de hospitais e melhorias contínuas para tornar a ferramenta de fato um objeto de auxílio na saúde pública e privada, para isso diversos fatores podem ser alterados com a finalidade de gerar um produto final ainda mais apto ao uso, entre essas possíveis melhorias algumas se destacam, entre elas, integração ainda mais forte com a nuvem, o que permitiria uma escalabilidade rápida e sem complicações, tecnologias como AWS permitiriam o uso de GPUs nos servidores da aplicação aumentando a capacidade de processamento e velocidade da resposta, a criação de um novo módulo na aplicação direcionada apenas aos pacientes também poderia contribuir muito para o projeto, esse novo módulo os permitiria, por exemplo, acessar suas análises e ver o diagnóstico médico diretamente dos seus próprios dispositivos móveis, também permitiria uma mudança nas regras de negócio da aplicação, no sentido de os médicos serem adicionados a um paciente, e não um paciente pertencer a um médico apenas, ou seja, a conta do paciente seria criada e a do profissional também e existiriam mecanismos internos que associariam os dois de acordo com a necessidade, essa mudança permitiria que diversos profissionais pudessem atuar em conjunto no decorrer de um tratamento de um detentor da úlcera, tornando a ferramenta ainda mais eficiente no contexto hospitalar.

Os modelos de classificação e detecção apresentaram métricas promissoras, demonstrando bons níveis de acurácia e precisão. Em futuros projetos, as arquiteturas mais eficientes podem ser selecionadas e treinadas de forma ainda mais estratégica. O uso da validação cruzada, por exemplo, pode garantir que o desempenho do modelo seja mais generalizável. Para elevar a performance, a aplicação de técnicas avançadas, como as descritas por Goyal et al. (2020), pode ser fundamental. A extração de características visuais por meio dos Superpixel Colour Descriptors (SPCD), que se concentram em cores específicas, como o vermelho e o preto, pode fornecer pistas cruciais para a classificação de isquemia e infecção. Além disso, a combinação de múltiplos modelos em um Ensemble CNN é uma estratégia poderosa para alcançar uma precisão superior, superando o desempenho de modelos individuais. Adotar essas abordagens pode levar a um avanço significativo na eficácia da aplicação.

Além do impacto tecnológico, o projeto possui relevância social e científica, uma vez que pode contribuir para reduzir amputações, otimizar o tratamento, e melhorar a qualidade de vida de milhões de pacientes diabéticos no mundo. O aplicativo, ao mesmo tempo em que apoia o diagnóstico, pode alimentar continuamente seu próprio banco de dados com imagens e diagnósticos médicos, abrindo espaço para um ciclo de aprendizado constante e de inovação contínua.

Em suma, este trabalho demonstra que a aliança entre inteligência artificial e saúde tem potencial transformador, e que iniciativas como esta pavimentam o caminho para uma prática médica mais eficiente, acessível e orientada por dados.

6. Referências

INTERNATIONAL DIABETES FEDERATION. **IDF Diabetes Atlas**. 10th ed. Brussels: IDF, 2021. Disponível em: <https://www.diabetesatlas.org>.

SUN, H.; SAEEDI, P.; KARURANGA, S.; PINKEPANK, M.; OGURTSOVA, K.; DUNCAN, B. B.; STEIN, C.; BASIT, A.; CHAN, J. C. N.; MBANYA, J. C.; PAVKOV, M. E.; RAMACHANDARAN, A.; WILD, S. H.; JAMES, S.; HERMAN, W. H.; ZHANG, P.; BOMMER, C.; KUO, S.; BOYKO, E. J.; MAGLIANO, D. J. IDF Diabetes Atlas: Global, regional and country-level diabetes prevalence estimates for 2021 and projections for 2045. **Diabetes Research and Clinical Practice**, v. 183, p. 109119, jan. 2022. DOI: <https://doi.org/10.1016/j.diabres.2021.109119>. Erratum em: *Diabetes Research and Clinical Practice*, v. 204, p. 110945, out. 2023

ARMSTRONG, D. G.; TAN, T. W.; BOULTON, A. J. M.; BUS, S. A. **Diabetic foot ulcers: a review**. *JAMA*, v. 330, n. 1, p. 62-75, 3 jul. 2023. DOI: <https://doi.org/10.1001/jama.2023.10578>.

WEATHERALL, T. et al. **The impact of machine learning on the prediction of diabetic foot ulcers – a systematic review**. *International Wound Journal*, [S. l.], 2023. DOI: <https://doi.org/10.1111/iwj.13920>. Acesso em: 19 ago. 2025.

ELLAHHAM, Samer. **Artificial Intelligence: The Future for Diabetes Care**. *The American Journal of Medicine*, v. 133, n. 8, p. 895-900, ago. 2020. Disponível em: <https://doi.org/10.1016/j.amjmed.2020.03.033>. Acesso em: 24 ago. 2025.

SANTOS, Elineide Silva dos; VERAS, Rodrigo de Melo Souza; SANTOS, Francisco das Chagas Torres dos; ITO, Márcia; BIANCHI, Andrea Gomes Campos; AIRES, Kelson Rômulo Teixeira; TAVARES, João Manuel R. S. **Enhancing Diabetic Foot Ulcer Classification Through Fine-Tuned Multilevel CNN**. *IEEE Access*, v. 13, p. 113702-113717, 2025. DOI: <https://doi.org/10.1109/ACCESS.2025.3583111>.

DFU CHALLENGE. **Diabetic Foot Ulcer Challenge (DFUC)**. Disponível em: <https://dfu-challenge.github.io/>. Acesso em: 21 ago. 2025.

ALZUBAIDI, Laith et al. **Diabetic Foot Ulcer (DFU) dataset**. Kaggle, 2020. Disponível em: <https://www.kaggle.com/datasets/laithjj/diabetic-foot-ulcer-dfu>. Acesso em: 21 ago. 2025.

GOYAL, M. et al. DFUNet: Convolutional Neural Networks for Diabetic Foot Ulcer Classification. **IEEE Transactions on Emerging Topics in Computational Intelligence**, v. 4, n. 5, p. 728-739, 2018. DOI: 10.1109/TETCI.2018.2866254.

CASSIDY, B. et al. Artificial intelligence for automated detection of diabetic foot ulcers: A real-world proof-of-concept clinical evaluation. **Diabetes Research and Clinical Practice**, v. 205, p. 110951, nov. 2023. DOI: <https://doi.org/10.1016/j.diabres.2023.110951>. PMID: 37848163. Acesso em: 24 ago. 2025.

HARAHAP, M. et al. **Classification of diabetic foot ulcer using convolutional neural network (CNN) in diabetic patients**. *JURNAL INFOTEL*, v. 14, p. 196-202, 2022. DOI: <https://doi.org/10.20895/infotel.v14i3.796>. Acesso em: 24 ago. 2025.

GOYAL, Manu et al. **Recognition of ischaemia and infection in diabetic foot ulcers: Dataset and techniques**. *Computers in Biology and Medicine*, v. 117, p. 103616, 2020.

ZHANG, Jianglin et al. **A comprehensive review of methods based on deep learning for diabetes-related foot ulcers**. *Frontiers in Endocrinology*, v. 13, p. 945020, 8 ago. 2022. DOI: 10.3389/fendo.2022.945020. Disponível em: <https://www.frontiersin.org/journals/endocrinology/articles/10.3389/fendo.2022.945020/full>. Acesso em: 26 ago. 2025.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI

PARTE III – RELATO DE DEMAIS ATIVIDADES

Descrição (Seminários, Congressos, Artigos publicados, e outros)	Local (Realizado ou publicado)	Período (Data realizado ou publicado)
(inserir uma atividade a cada linha)		

Da formatação do documento:

A CPESI/PROPESQI/UFPI define que os **relatórios** de ATIVIDADES DOS PROGRAMAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO devem seguir, **necessariamente**, as seguintes instruções.

- a) O relatório deve conter três partes: PARTE I – IDENTIFICAÇÃO; PARTE II – RELATO TÉCNICO-CIENTÍFICO, e PARTE III – RELATO DE DEMAIS ATIVIDADES.
- b) A PARTE II, deve conter seis seções numeradas com os títulos: 1. Introdução; 2. Revisão de Literatura; 3. Metodologia; 4. Resultados e discussão; 5. Conclusão; 6. Referências; com alinhamento à esquerda.
 - b.1. As subseções devem também ser numeradas conforme o número da seção da PARTE II.
 - b.2. Na seção de Referências, as obras da literatura citadas, devem seguir as normas da ABNT NBR 10520 e NBR 6023.
 - b.3. Tamanho da fonte – é 10, e o alinhamento justificado em todo o documento.
 - b.4. Fonte – Tipo Arial em todo o documento;
 - b.5. Todas as margens – 2 cm cada;
 - b.6. Recuo de parágrafo – primeira linha à 1,25 cm;
 - b.7. Paginação – ativado Controle de linhas órfãos/viúva;
 - b.8. Espaçamento – 0pt antes e 0pt depois;
 - b.9. Espaçamento em entrelinhas – simples;
 - b.10. Número de páginas – arábico, no rodapé, à direita (não precisa informar).
 - b.11. Espaçamento entre texto e Ilustração (Figura/Quadro/Gráfico) ou Tabela – um espaço vazio;
 - b.12. O título de Ilustração (Figura/Quadro/Gráfico) ou Tabela possui numeração arábica, separada por dois-pontos, à esquerda, sem negrito.
 - b.13. A Ilustração (Figura/Quadro/Gráfico) ou Tabela devem indicar a fonte.

RELATÓRIO DE ATIVIDADES – PROGRAMAS DE INICIAÇÃO TECNOLÓGICA DA UFPI
